



Machine Learning Algoritmi: i problemi di apprendimento sono risolvere uno specifico problema a partire da un set di dati

Campione: sottosezione di un popolazione

Risultato:  $D_s \cdot D_t / 2$  Dati  $\rightarrow$  Algoritmo  $\rightarrow$  Output

Ciascuno di n. di elementi del campione si chiama esempio

3 problemi con piede di incertezza:

prob. valuto & p. se un dollore  $\rightarrow$  classificare un inz. per stabilire quale gelto è necessario

Distinguere SPAM  $\rightarrow$  SPAM  
NON SPAM  $\rightarrow$  Non SPAM

Altre incertezze, non riuscite a sapere cosa succede per risolvere problemi

Guardare contenuto email  $\rightarrow$  SPAM  
 $\rightarrow$  NON SPAM  $\rightarrow$  Non vi è sempre modo logico

DATI INPUT  $\rightarrow$  ALGORITMO  $\Rightarrow$  OUTPUT

DATI INPUT  $\rightarrow$  [Algoritmo learning]  $\rightarrow$  Programma  
OUTPUT

A) Problema di learning

relativo alla obiettività

Un computer apprende da un'esperienza E rispetto ad un task T ad una classe di parametri D.  
Se le parametri P misurati su E ragionano con l'esperienza rispetto ad un task T

TASK: problema da risolvere  $\rightarrow$  Modello

valutato su  
↓  
Funzione  
parametrica  
L'h

ESEMPIO: DATI

g. n. de valori notabili se basta sapere che tipo di input

PERFOMANCE:  $P(\{y^{(i)}\}_{i=1}^m, \{\tilde{y}^{(i)}\}_{i=1}^m)$

Generalità

Vd. Hto  $\rightarrow$  fine

parabola

Calcolo  
parametri

$$h(x^{(i)}) = \hat{y}^{(i)}$$

$$p \in [0,1]$$

$(1-p \Rightarrow)$  Flusso di Borda

Prob. Modelli logici  $\rightarrow$  Modelli statisticci che discriminano fra tante

Fattore  $\rightarrow$  Espressione di effetto

Parziali  
Cognitivo  
Emotivo  
Materiale

In esempio  $x = (x_1, \dots, x_d)$

(i) > var. dist. da casa

(ii) >  $x^{(1)}, x^{(2)}, \dots, x^{(d)}$

[ ]  $\rightarrow$  utile oggi in classe

notte in loco (att. scuola) poi  
Dove si trascorrono i tempi

## Estrazione Feature

$$P(x) = \bar{x} \quad \text{Cosa è avere}$$

Apprendimento

$$\Rightarrow x^i.$$

Non usare RAPP. universale

A prima vista dati  $\rightarrow$  Ostiene cose, importanti rispetto al task de risoluzione

## Tipi di Teste

regressione

$$x \in \mathbb{R}^d, y \in \mathbb{R}$$

classificazione

$$x \in \mathbb{R}^d, y \in \{1, \dots, k\} \text{ k.m. classi predispinte}$$

$$h_{\theta}(x) = y$$

$$h \text{ puriss. : } \mathbb{R}^d \rightarrow \{1, \dots, k\}$$

## Tipi di Learning

Supervised Learning

$$\begin{cases} x \\ y \end{cases} \in \mathbb{R}^n$$

Unsupervised Learning

$$x \in \mathbb{R}^n$$

## Reinforcement Learning

Prova d'azione

Stimare se azione ha per giuovo il suo scopo

Accum +  $\rightarrow$  CLASSIFICAZIONE

Grad. Theta

$\rightarrow$  % di risposte corrette date in output  
di uno algoritmo di ML

PREGRAZIONE  $\rightarrow$  ERRORE

ESPLORAZIONE = DATI

$$X = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \in \mathbb{R}^{m \times d}$$

Colonna  
contiene: Feature

$$(x_1^{(1)}, x_2^{(1)}, \dots, x_d^{(1)})$$

$$(x_1^{(2)}, x_2^{(2)}, \dots, x_d^{(2)})$$

$$\vdots$$

$$(x_1^{(n)}, x_2^{(n)}, \dots, x_d^{(n)})$$

Set di dati  $\rightarrow$  DATI  $\rightarrow$  Design Matrix

$$X \in \mathbb{R}^{m \times d}$$

$$Y = DATA \in \mathbb{R}^{m \times k}$$

$$A = \{1, \dots, k\} \quad k = 1$$

# Learning / training del Modello

Prende in input BANCHE DI Dati

Modello (Parametri)

Metri di Performance

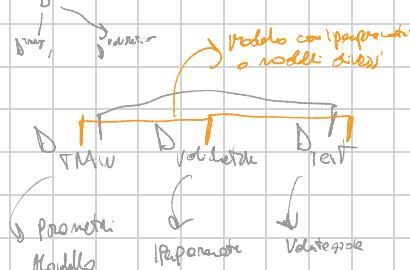
Output

Set di Parametri

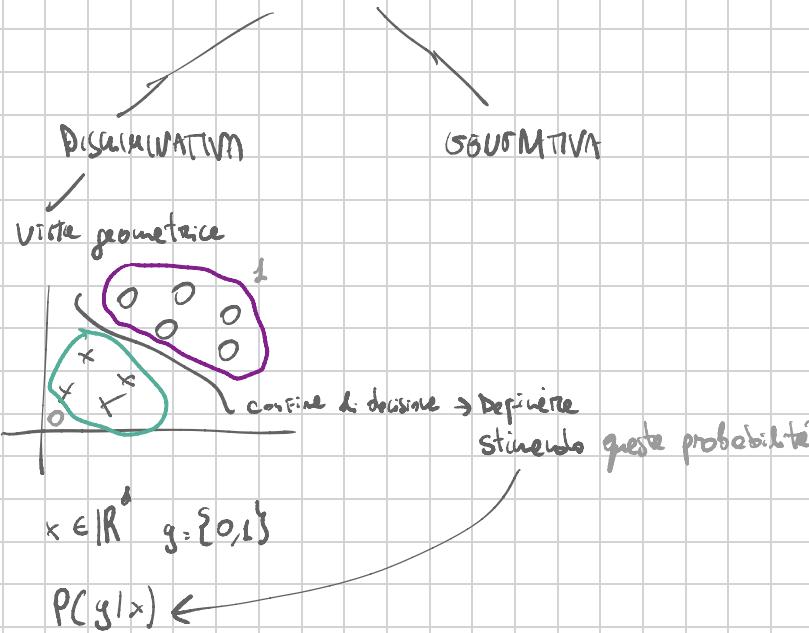
che producono le migliori performance su D

Vedere se

Generalizzabile



## CLASSIFICAZIONE



$$\text{Regola di Bayes} \rightarrow P(x|y)P(y) = P(y,x) = P(x)P(y|x) \quad P(x,y)$$

ipovedenti

Modello

Loss function (Risultato avuto)

| Algoritmo d'Learning

Evaluation

Semplice macchina campionevole  $\rightarrow$  Macchine

1 Modello

Modello McCulloch-Pitt 1943

### Modello neurone

Unità computazionale che riceve e produce un input binario

Modello return output binario

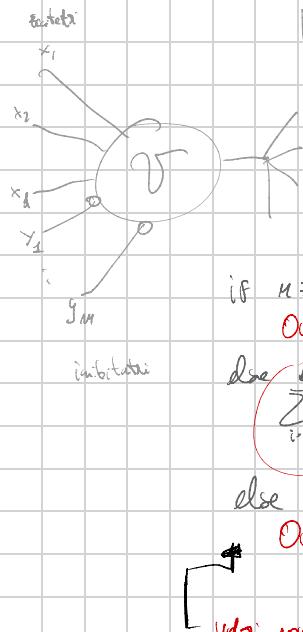
Ogni neurone è associato ad un potenziale  $\theta$  (threshold)

Output può essere causato da altri neuroni (anche più di uno)

Input può provare da altri neuroni oppure essere binario o avere componenti

Due tipi di input

Excitatorio  
Inibitorio



se inibitore attivo  $\Rightarrow$  output = 0 Attivato

if  $M \geq 1$  AND  $\exists g_j | g_j = 1$  then

Output 0

else

$\sum_{i=1}^M x_i \geq \theta$  then

Output 1

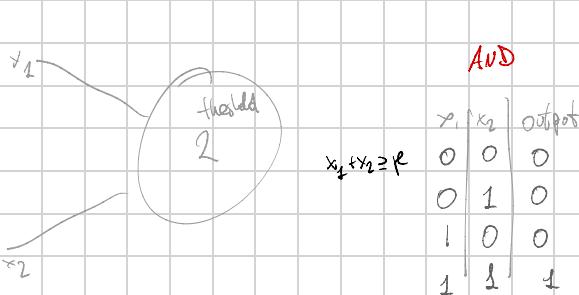
else

Output 0

Valeva non binari in binari



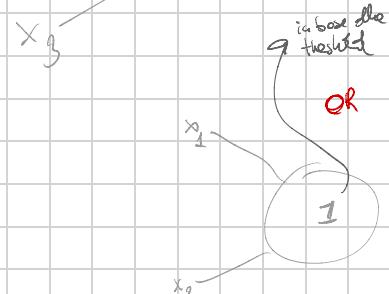
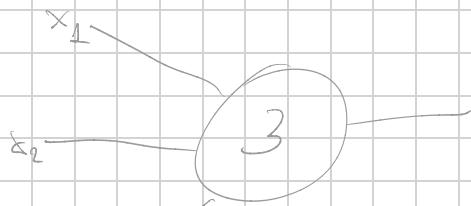
Dobbiamo avere per output



AND

$x_1$	$x_2$	output
0	0	0
0	1	0
1	0	0
1	1	1

$x_1 + x_2 \geq \theta$



OK

# Modello Parametrizzato

Funzione lineare

Valori soglie + inhibit = progetto

Limiti Modello

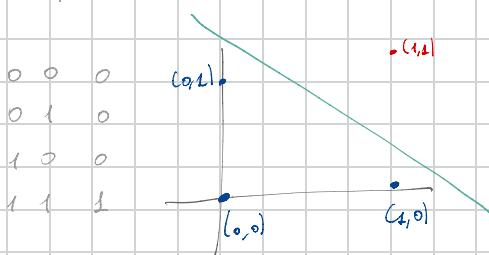
Perotto può ricevere binari

Perotto solo per percorsi lineari / input binari

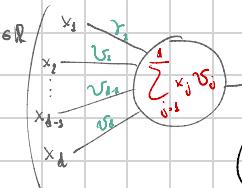
Parametri fissati a zero → No procedure di learn

Non esistono pesi

Tutte le funzioni sono linearmente separabili → frontiere HVS separate con classi  
dove posso mettere su ogni binario



Parotterazione



aggiungo tutte le pesi  
agli input come input

No Compte combinatorie lineare del resto input  
stesso modello

$$J = \{0, 1\}$$

Compte  $f(x_1, \dots, x_d) = \begin{cases} 1 \\ 0 \end{cases}$  se  $\sum v_j x_j > v_0$

ALTRIMENTI

$$x_0 = 1, x_1, \dots, ?$$



$\uparrow$

decision border

$$v_0 + x_1 v_1 + x_2 v_2 = 0$$

→ eq. rettific

$$x_2 = \left( \frac{v_1}{v_2} \right) x_1 - \frac{v_0}{v_2}$$

i punti  
al limite del resto input

$$y = m \cdot x + q$$

Come farcire e fissare i parametri?

$$\sum_j v_j x_j \geq 0 \quad \bar{g} = 0 \quad \bar{g}^1 = 1 \quad \text{Come posso sintetizzare i pesi?}$$

$\xrightarrow{\text{risposta}}$   
 $x \in \mathbb{R} \rightarrow x \in \{0,1\}$  Diametrali i parametri

$$S \in \{0,1\}^L$$

$$y = 1 \quad \bar{g} = 0$$

$\leftarrow$  come  
fissare  
pesi

$\leftarrow$  comp.

Inizializziamo i parametri

$v_j \leftarrow v_j + (y - \bar{g}) x_j$

$\downarrow$  quantità  
pesi esistenti  
 $y \in \{0,1\}$

poniamo

l'initializzazione dei pesi zerdano in  $\{0,1\}$

Considerare  $x^{(i)}$  e computo  $\bar{g}^{(i)}$   $\forall i$

Per le precisioni tenute approssima i pesi:

$$y = 0 \quad \bar{g} = 1 \quad \text{Discreta}$$

$$y = 1 \quad \bar{g} = 0 \quad \text{Inizializzazione}$$

$$v_j \leftarrow v_j + (y - \bar{g}) x_j$$

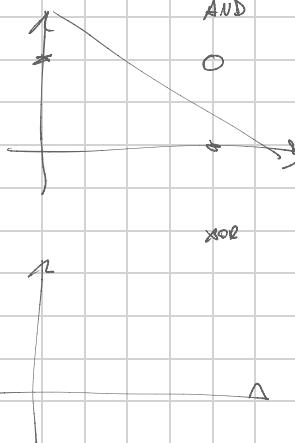
Al termine del passo 2 il vettore è convergente

$\rightarrow$  Convergenza vettore  $\times$  approssimazione

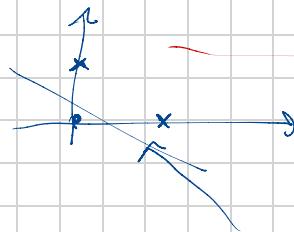
$$[f_v(x) > 0]$$

xor

$x_1$	$x_2$	AND	OR	xor
0	0	0	0	0
0	1	0	1	1
1	0	0	1	1
1	1	1	1	0



$$\begin{aligned} v_0 + x_1 v_{11} + x_2 v_{12} > 0 \\ x_1 v_{11} + x_2 v_{22} > -v_0 \end{aligned}$$



$$0v_1 + 0v_2 < t \Rightarrow t > 0$$

$$0v_1 + 1v_2 > t \quad v_2 > t > 0$$

$$1v_1 + 0v_2 > t \quad v_1 > t > 0$$

$$1v_1 + 1v_2 < t \quad v_1 + v_2 < t$$

$$v_1 > 0 \quad t > v_1 + v_2 > 2t$$

$$v_2 > 0$$

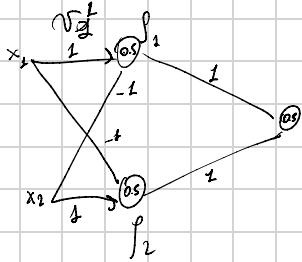
$x_1$	$x_2$	$f_1$	$f_2$	$f_3$
0	0	0	0	0
0	1	1	0	1
1	0	1	1	1
1	1	0	0	0

Risolviamo il problema xor

$$v_0' = 0.5$$

$$v_1' = 1$$

$$v_2' = -1$$



$$f_1(x_1, x_2) = [x_2 - x_1 > 0.5] \quad \begin{cases} 0 \\ 1 \end{cases}$$

$$f_2(x_1, x_2) = [x_2 - x_1 < 0.5] \quad \begin{cases} 0 \\ 1 \end{cases}$$

$$f_3(f_1(x_1, x_2), f_2(x_1, x_2)) = [f_1(x_1, x_2) + f_2(x_1, x_2)] \quad \begin{cases} 0 \\ 1 \end{cases}$$

valore finale

Risolviamo ora il problema xor

Molto coi 3 neuroni risolviamo il problema xor

backpropagation

Problema xor rimane → non separabile con linee

# Regressão

## Modelo

Loss Function  $\rightarrow$   $f_{\text{loss}}$  entre pred.

Algoritmo de Learning

Evaluations

quadro comparação de dados  
 → erro de dada  
 $\sum (y^{(i)} - \hat{y}^{(i)})^2 = g_{\text{loss}}$

$$\hat{g}^{(i)} = \begin{bmatrix} g_1^{(i)} \\ \vdots \\ g_n^{(i)} \end{bmatrix}$$

Task Regression

$f: \mathbb{R}^m \rightarrow \mathbb{R}^n$   $\Rightarrow$  value in input  
 value in output  
 para cada

TRAINING

$$\mathbb{R}^m \times \mathbb{R}^n$$

DATA  $\rightarrow$  VALIDATION

TEST

Mean Square Error

$\rightarrow$  Distância Euclidiana

$$\hat{g}_{\text{loss}} = \left\{ f_{\text{loss}}(x^{(i)}) \right\}_{i=1}^m$$

$$\hat{g}^{(i)} = \begin{bmatrix} g_1^{(i)} \\ \vdots \\ g_n^{(i)} \end{bmatrix}$$

$$\| \hat{g}^{(i)} - g^{(i)} \|_2 = \sqrt{\sum_{j=1}^n (g_j^{(i)} - \hat{g}_j^{(i)})^2}$$

$$\text{ENVIOS}(\hat{Y}_{\text{loss}}, g_{\text{loss}}) = \frac{1}{m} \sum_{i=1}^m \| \hat{g}^{(i)} - g^{(i)} \|_2$$

MSE

DIFERENÇA MÉDIA ABSOLUTA

Valeu fn peso de + ERROU GRANDE

maior erro de cálculo

$$f_{\text{loss}}: \mathbb{R}^m \rightarrow \mathbb{R}^n$$

↑ enes

$m = n = 1 \rightarrow$  Simple Regression  $\rightarrow f_{\text{loss}}(x) = g$   
 m > 1 AND n = 1  $\rightarrow$  Multiple regression  $\rightarrow f_{\text{loss}}(x) = g$   
 m > 1 AND n > 1  $\rightarrow$  Multivariate Regression  $\rightarrow$  in geral p/ pred. mais variáveis

## Modelo linear Regressão

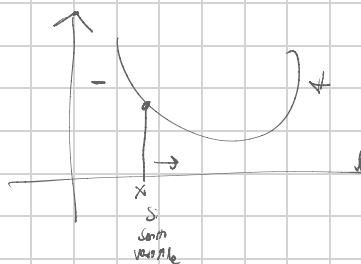
Loss Function

$$f_{\text{loss}}(w) = v_0 + w_1 v_1 + \dots + w_m v_m$$

$$J(w) = \frac{1}{2} \sum_{i=1}^m (f_{\text{loss}}(v_i) - g^{(i)})^2$$

$\hat{v} = \arg \min_w J(w)$

DISPONIBILIT



$$w_f^{(0)} =$$

valor inicial

em regulação

$$\underbrace{\nabla J(\nabla)}_{\nabla \nabla_j} = \sum_{i=1}^m (\nabla_0 + x_1 \nabla_1 + \dots + x_m \nabla_m - g) x_i = \sum_{i,j}^m (f_{\theta^t}(x_i) - g^{(t)}) x_j$$
$$v_j \leftarrow v_j - \gamma \sum_{i,1}^m (f_{\theta^t}(x_i) - g^{(t)}) x_i^{(t)}$$