



Machine Learning Algorithmi in grado di apprendere come risolvere uno specifico problema a partire da un set di dati


Campione: orza di un poligono

$$\text{Roubo} \quad D_s - D_s/2 \quad \text{Dati} \rightarrow \text{Algoritmo} \rightarrow \text{Output}$$

Ciascun al. di classificazione ha un ruolo in un testo

I problemi con piede di incertezza

→ prob. molto basso se modellare → classificare un ist. più stabile
quale getto i pezzi



Altre incertezze, non riuscite a troppi esempi per risolvere problemi

Guardare contenuto SPAM
→ Non vi è sempre modo logico

DATI → Algoritmo → OUTPUT



A) Problema di Learning

Un computer apprende se vi esporre E rispetto ad un task T ad una misura di performance D.

Se le performance P misurate su E migliorano con l'esposizione rispetto ad un task T

$$h_\theta(x)$$

Task: Problema da risolvere → Modello

↓
valutato su
Funzione
parametrica
 h

ESEMPIO : DATI

→ misure da valutare quando si trova spazio vuoto dentro un input

$$\text{PERFORMANCE: } P(\{y^{(i)}\}_{i=1}^m, \{\hat{y}^{(i)}\}_{i=1}^m)$$

[Generalità]




$$h(x^{(i)}) = \hat{y}^{(i)}$$

$$p \in [0, 1]$$

$(1-p \Rightarrow)$ Flusso di Borda

Prob. Modelli logici \rightarrow Modelli statisticci che DIPENDONO dal TASSO



In esempio $x = (x_1, \dots, x_d)$

$$x^{(i)} \xrightarrow{\text{caso di testo}} x = (x_1^{(i)}, x_2^{(i)}, \dots, x_d^{(i)})$$

[] [] $\xrightarrow{\text{tutte le righe in classe}}$

NOTA IN LUCI DELLA STORIA DELL'INFORMATICA
DALL'INVENTORE AL PIONIERE

Ottimizzazione Feature

$$P(x) = \bar{y}$$

Apprendimento

Criterio di apprendimento

NON esiste PAPR. universale

A prima vista detti \rightarrow ottimizzare i coefficienti, permettendo di ridurre le residue

Tipi di Teste

regressione
 $x \in \mathbb{R}^d, y \in \mathbb{R}$

classificazione

$$x \in \mathbb{R}^d, y \in \{1, \dots, k\} \quad k \text{ n. classi predette}$$

$$h_{\theta}(x) = y$$

più prevedibile

Tipi di Learning

Supervised Learning

$$\begin{cases} x \\ y \end{cases} \in \mathbb{R}^n$$

Unsupervised Learning

$$x^{(i)} \in \mathbb{R}^n$$

Reinforcement Learning

Prova d'azione

Sistemi se stessi hanno per ottenere il loro scopo

Accumulo \rightarrow CLASSIFICAZIONE

Grad. Theta

% di risposte corrette date in output
di uno algoritmo ML

Coppia di valori \rightarrow REGRESSIONE \rightarrow ERRORE

Attributi = Features

ESPERIENZA = DATI

colonna
contiene: feature
esempio
feature
feature

Set di dati \rightarrow DATI \rightarrow Design Matrix

$x \in \mathbb{R}^{m \times d} \rightarrow$ esempio \times feature

$m \times k \rightarrow$ etichette

$y \in \mathbb{R}^{m \times 1}$

$$A = \{1, \dots, k\} \quad k = 1$$

Learning / training del Modello

Prende in input B_{AUC} DFT

Modello (Parametri)

Metri di Performance

Output

Set di Parametri

che producono le migliori performance su D

Voltazione

Generalizzabilità

D_{train}
D_{test}

D_{train}
D_{test}

D_{train}
D_{test}

D_{train}
D_{test}

D_{train}
D_{test}

Modello con i parametri
o modello ottimo


Parametri

Modello

Performance

Voltazione

CLASSIFICAZIONE



$$\text{Regola di Bayes} \rightarrow P(x|y)P(y) = P(y|x) = P(x)P(y|x) \quad P(x,y)$$

Input dati \rightarrow Classificazione

Modello

Loss function (Risultato atteso)

| Algoritmo d'Learning

Evaluation

Semplice macchina campionatrice \rightarrow Macchine

1 Koddle

Koddle McCulloch-Pitt 1943

Univore neurone


Unità computazionale che riceve e produce un input binario

Koddle return output binario

Ogni neurone è associato ad un potenziale θ (threshold)

Output può essere causato da altri neuroni (anche più di uno)

Input può provare da altri neuroni oppure essere binario o avere componenti
Due tipi di input 



se inibitore acceso \Rightarrow output = 0 (inibito)

if $m \geq 1$ AND $\exists j | g_j = 1$ then

Output 0

inibitori

~~else~~ FP $\sum_{i=1}^n x_i \geq R$ then

Output 1

else


Output 0

Vedi: non binari in binari

Step function




Dobbiamo pensare per output



AND


x_1	x_2	output
0	0	0
0	1	0
1	0	0
1	1	1

$x_1 + x_2 \geq R$




in base alla
threshold

OK



x_1	x_2	x_3	output
0	0	0	0
0	0	1	0
0	1	0	0
1	0	0	1
1	0	1	0
1	1	0	0
1	1	1	1

1 0 1
0 1 1
1 1 1



Modello Parametrizzato

Funzione lineare

Valori soglie + inhibit = progetto

Limiti Modello

Perotto può ricevere binario


Perotto solo per percorsi logici / input binari

Parametri fissati a zero → No procedure di learn


* Non esistono pesi

Tutte le funzioni sono linearmente separabili → frontiera HVS separata con classi

dove posso mettere su uno binario



Parotterazione



$$[v_0 \ v_1 \ v_2] \cdot [w_1 \ w_2 \ w_3] = X$$

$$v_0 + v_1 w_1 + v_2 w_2 = 0$$

→ eq. rettific

$$w_2 = \frac{v_0}{v_2} w_1 \rightarrow v_2 = \frac{v_0}{w_2} w_1$$

i pesi
del resto del resto input

$$y = m \cdot x + q$$

Come farcire e fissare i parametri?

$$\sum_j v_j x_j \geq 0 \quad \bar{g} = 0 \quad \bar{g}^1 = 1 \quad \text{Come posso sintetizzare i pesi?}$$

$x \in \mathbb{R} \rightarrow x \in \{0,1\}$ Diametria i parametri

$$S \in \{0,1\}^L$$

$$y = 1 \quad \bar{g} = 0$$

Brutto
caso 2
caso 1
caso 2
caso 1

L'incremento i parametri
luminosità
 $v_j \leftarrow v_j + (y - \bar{g}) x_j$
quanti
pic esponente
in $\{0,1\}$

permettendo

l'incremento i pesi restano in $[0,1]$

Considerare $x^{(i)}$ e compito $\bar{g}^{(i)}$ $\forall i$

Per lo precisione rettificare i pesi:

$$y = 0 \quad \bar{g}^1 = 1 \quad \text{Discreta}$$

$$y = 1 \quad \bar{g} = 0 \quad \text{luminosità}$$

$$v_j \leftarrow v_j + (y - \bar{g}^1) x_j$$


Al termine del passo 2 il vettore è convergente

→ Conserves vettore x aggiustare pesi

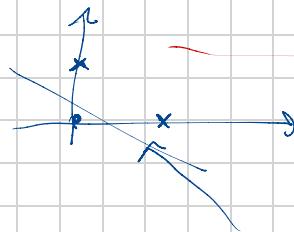
$$[f_{\text{v}}(x) > 0]$$

xor

x_1	x_2	AND	OR	xor
0	0	0	0	0
0	1	0	1	1
1	0	0	1	1
1	1	1	1	0



$$\begin{aligned} v_0 + x_1 v_1 + x_2 v_2 > 0 \\ x_1 v_1 + x_2 v_2 > -v_0 \end{aligned}$$



$$0v_1 + 0v_2 < t \Rightarrow t > 0$$

$$0v_1 + 1v_2 > t \Rightarrow v_2 > t > 0$$

$$1v_1 + 0v_2 > t \Rightarrow v_1 > t > 0$$

$$1v_1 + 1v_2 < t \Rightarrow v_1 + v_2 < t$$

$$v_2 > 0 \quad t > v_1 + v_2 > 2t$$

$$v_2 > 0$$


x_1	x_2	f_1	f_2	f_3
0	0	0	0	0
0	1	1	0	1
1	0	1	1	1
1	1	0	0	0

Risolviamo il problema xor

$$v_0' = 0.5$$

$$v_1' = 1$$

$$v_2' = -1$$



$$f_1(x_1, x_2) = [x_1 - x_2 > 0.5] \quad \begin{matrix} 1 \\ 0 \\ -1 \end{matrix}$$

$$f_2(x_1, x_2) = [x_2 - x_1 > 0.5] \quad \begin{matrix} 0 \\ 1 \\ -1 \end{matrix}$$

$$f_3(x_1, x_2) = [x_1 + x_2 > 0] \quad \begin{matrix} 1 \\ 1 \\ 0 \end{matrix}$$

Risolviamo ora il problema xor

$$\begin{aligned} v_0^2 &= 0.5 \\ v_1^1 &= 1 \\ v_2^1 &= -1 \end{aligned}$$

Risolviamo ora il problema xor

Applicazione

Problema xor simile → non separabile caso allineato

Regressão

Modelo

for x to addressees
for y

Loss Function

Aj. other pes:

Algoritmo de Levenberg

Evaluation

Test

quanti campioni e dati
 $\sum_{i=1}^m g^{(i)} = \bar{g}$ test
 $\sum_{i=1}^m g^{(i)} = \bar{g}$ campioni

$$\bar{g}^{(i)} = \begin{bmatrix} g_1^{(i)} \\ \vdots \\ g_n^{(i)} \end{bmatrix}$$

Vista Regressão

$f: \mathbb{R}^m \rightarrow \mathbb{R}^n$
v
pendente

vista predita

vista input
vista output

TRAINING

DATA VALIDATION

TEST

R^2 R^2'
 x y

Mean Squared Err

Distância Euclidiana

$$\| \bar{g}^{(i)} - \bar{g} \|^2 = \sum_{j=1}^n (g_j^{(i)} - \bar{g}_j)^2 \rightarrow \text{distância euclídea}$$

$$\text{ENORM}(Y_{\text{TEST}} | \bar{g}_{\text{TEST}}) = \frac{1}{m} \sum_{i=1}^m \| \bar{g}^{(i)} - \bar{g}^{(i)} \|^2$$

MSE

DISTRIBUÇÃO RADIAL CONDUZIDA

Voltar para pesar $\beta_i + \text{ERRO DE MUN}$

↓ media erro da constante

$$f_v: \mathbb{R}^m \rightarrow \mathbb{R}^m$$

enée

$m = m' = 1 \rightarrow$ Simple Regression \rightarrow pes $f_v(x) = g$
 pes β_0
 $m > 1$ AND $m' = 1$ Multiple regression $\rightarrow f_v(x) = S$
 $m > 1$ AND $m' > 1$ Multivariate Regression \rightarrow object recognition


Modelo Linear Regressão

Loss Function

$$f_v(w) = w_0 + w_1 x_1 + \dots + w_m x_m$$

$$f_v(w) = \frac{1}{2} \sum_{i=1}^m (f_v(x_i) - g^{(i)})^2 \rightarrow \text{Diferença entre}$$

$$\hat{w} = \text{off min } f(v) \rightarrow \text{aperto de mínimo possível}$$



$$w_f^{(0)} =$$

versor final
cotação

$$\underbrace{\sum_j v_j}_{\text{J(v)}} = \sum_{i=1}^m (v_0 + v_1 x_1 + \dots + v_m x_m - g) x_i = \sum_{i=1}^m (f_{\theta}(x^{(i)}) - g^{(i)}) x_i$$

$$v_j \leftarrow v_j - \frac{1}{m} \sum_{i=1}^m (f_{\theta}(x^{(i)}) - g^{(i)}) x_i$$

\Rightarrow learning rate α
 $=$ $\frac{1}{m}$ gradient norm times μ

$$\sum_v(x) = \sum^d x = v_0 + v_1 x_1 + v_2 x_2 + \dots + v_d x_d \quad x \in \mathbb{R} \quad d \geq 2$$

$$d=1 \quad v_0 + v_1 x_1$$

$$\phi(x) \in \mathbb{R}^d$$

dimensione

$$d=1 \quad x_1 \xrightarrow{\phi}$$

$$\begin{matrix} x_1 \\ x_2 \\ x_3 \\ \vdots \\ x_d \end{matrix}$$

$$\sum_v(\phi(x)) = \sum_{i=1}^d x_i = v_0 + v_1 x_1 + v_2 x_2 + \dots + v_d x_d$$

$d > 1$ Interaction Point

$$\Rightarrow J(v) = \frac{1}{2} \sum_{i=1}^m (\sum_v(x^{(i)}) - g^{(i)})^2$$

[Loss Function]

Tra le esercitazioni che minimizzano la parola $J(v)$

Disease del frequentatore

Verifica

$$\text{MSE} \quad \frac{1}{m} \sum_i (\sum_v(x^{(i)}) - g^{(i)})^2 \approx J(v)$$

sotto pochi tratti
 \downarrow
 molto gesto


M A E

g Semantic problem

$$\frac{1}{m} \sum_{i=1}^m \left| f_{\theta}(x^{(i)}) - g^{(i)} \right|$$

où de la distance
Semantic più precise

idea di distanza \rightarrow Minimax!



$$RMSE \rightarrow RMSD = \sqrt{MSE} \longrightarrow$$
 come si distribuisce

BAGNA dati \rightarrow SPLIT

\hookrightarrow Si mantiene

Rec Curve \rightarrow Così ripartire

Campioni di test / campioni di test $(x^{(i)}_{test})_{i \in S}$ $\rightarrow \epsilon_i$

valore corrente

$$\begin{matrix} x^{(0)} & \epsilon_0 \\ \vdots & \vdots \\ x^{(n)} & \epsilon_n \end{matrix}$$


come

errori piccoli

\hookrightarrow come picco ad evitare?

Solti

\downarrow
 $\epsilon_0, \dots, \epsilon_n$



caso di elementi

quanti di essi

potranno

$\leq m$

n. di elementi $x^{(i)}$ con errore $\leq \epsilon_j$

raggi ore sotto curva \rightarrow riflette il risultato

voglio così piccole

es

$$m=5 \quad \epsilon_1 = \frac{2}{m}, \quad \epsilon_2 = \frac{3}{m}, \quad \epsilon_3 = \frac{3}{m}, \quad \epsilon_4 = \frac{4}{m}, \quad \epsilon_5 = \frac{5}{m} = 1$$

Rette

$$\Gamma = \begin{bmatrix} x_0^{(0)} & \dots & x_d^{(0)} \\ x_0^{(1)} & \dots & x_d^{(1)} \\ \vdots & \ddots & \vdots \\ x_0^{(m)} & \dots & x_d^{(m)} \end{bmatrix} \begin{bmatrix} f^{(0)} \\ \vdots \\ f^{(m)} \end{bmatrix} = \emptyset$$

eq normale

$$V = \underbrace{\text{Min}_{\Gamma} J(V)}_{\text{Rette attuale}} = \left(\Gamma^T \Gamma \right)^{-1} \Gamma^T f$$

$\Theta(d^3)$ $\rightarrow d \text{ m feature per } n \text{ piccoli } d$
 $\text{if } d \gg n \Rightarrow \text{Complexità esplosiva}$


gesto dove once inviatibile

$$\begin{array}{c} (d+1) \times (d+1) \\ | \quad \quad \quad | \\ (d+1) \times m \quad m \times 1 \\ \downarrow \\ (d+1) \times 1 \end{array}$$

CAPACITÀ del Modello

Capacità Modello

Modello capace di ridursi però complesso:




Modello buone varie
base


BEST AND POSSIBLE
" " TEST

UNDERFITTING

→ Modello non capace e generalizzare su campioni nuovi



HIGH BIAS



FEW
Training opposite Test

cose buono train

cose dico test

OVERTFITTING

HIGH VARIANCE

Combina di poco train
modello capisce tutto bene!

THINGS buono train

cose buono test

$J(\bar{y})$
TEST

$J(\bar{y})$
TEST

Modello troppo capace → Training
test NO!

upset
minimizing
gradi
Repetere
→ stessa cose se dati
molti sul modello

$$\text{Loss} \left(\int_{\Omega} u(x, y) \right) = J(\bar{y})$$

$$+ 1000 \bar{y}_3 + 1000 \bar{y}_4 \\ \bar{x}_0 \quad \bar{x}_0$$

semplicifico il modello

Voglio semplificare il modello

Durante le ppe di Training

invece di $J(\bar{y})$

utilizzo prior da predire

$$J(v) = \frac{1}{2} \sum_{j=1}^J v_j^2$$

Regolarizzazione
prende ampiezza
entro tutto troppo complesso per i nostri dati

→ Loss Function
Regolarizzata
Grazie al termine L
1:01 importante

OKAY

Af. di Leonty → Discese del gradiente

Model Selection \rightarrow Set di dati

$$J_{\text{DRAW}}(v)$$

$$\hat{J}_{\text{DRAW}}(v)$$

calcolo con MSE $\approx J_{\text{TEST}}(\hat{v})$

$\boxed{\text{TRAIN}}$
60%

$\boxed{\text{VALIDATION}}$
20%

$\boxed{\text{TEST}}$
20%

$$\int_v^{(1)} x^{(i)} = v_0 + v_1 x_0$$

$$\int_v^{(2)} x^{(i)} = v_1 x_1 v_2 + v_2^2 v_0$$

$$\int_v^{(k)} (x^{(i)})$$

$$\hat{J}^{(1)} = \min_{\text{DRAW}} J(v^{(1)})$$

$$\hat{J}^{(2)}$$

scelta

$$\hat{J}^{(i)}$$

$$J_{\text{VAL}}(\hat{v}^{(1)})$$

$$J_{\text{VAL}}(\hat{v}^{(2)})$$

fare modello dopo
averlo su validazione


$$J_{\text{VAL}}(\hat{v}^{(i)})$$

minimizzando parziale 100

min. errore su validazione!


Pratico minimo = seleziono modello

Valido modello $\approx J_{\text{TEST}}(\hat{v}^{(i)})$



Volumen up to pleno evolution

δ BUT \rightarrow Plotne evolu




$$J_{TMN} + \frac{1}{2} \lambda \sum v_i^2$$


Conc sols λ ?

$$\begin{aligned}
 \lambda^{(1)} &= 0.01 & v^{(1)} &= & J_{VAL}(v^{(1)}) \\
 \lambda^{(2)} &= 0.02 & v^{(2)} &= & J_{VAL}(v^{(2)}) \\
 &\vdots & & & \vdots
 \end{aligned}$$

Anotato m. copia baci fatti ufficio parziale?




$$U_0 + U_2 x_1 + U_3 x_2^2$$



underfilling ovariale m. var ei anche!
overfilling ovariale m. ei anche!

(\rightarrow PES) J^{TMIN} A₁₁₁ su J^{VAC}

Classificazione



Multo Prezioso
Loss Function
Alg Learning
Valore

$$z \in \mathbb{R}$$

$$g \in \{0, \dots, k-1\}$$

$$n = 10$$

$$d = 2$$



Multiclasse

Più classificatori binari

ONO VS ALL

ONO VS ONE

1	Tutte	Positive
0	Nerostate	Negativi

Solo 1 = dimensione patch

class. bicerie


$$\{0, 1\}$$

$$h_{\theta}^k(x) \in \mathbb{R}$$

$h_{\theta}^k(x) \geq 0,5 \rightarrow$ Assegna classe 1

$h_{\theta}^k(x) < 0,5 \rightarrow$ Assegna classe 0

min. errore per patch




Rettangolo min.

x nuovo punto!
classe classe L!

Problema!

Modello $0 \leq h_{\theta}^k(x) \leq 1$

Non buon idee ottimizzare




$$h_v(x) = \sigma(v^T x)$$

$$\sigma(z) = \frac{1}{1 + e^{-z}} = \frac{e^z}{e^z + 1} = \frac{e^z}{e^{2z} + 1}$$

Sigmoid

$$v = \begin{bmatrix} v_0 \\ \vdots \\ v_d \end{bmatrix}$$

$$x = \begin{bmatrix} x_0 \\ \vdots \\ x_d \end{bmatrix}$$



$$h_v(x) = \sigma(v^T x) = P(y=1|x, v)$$

$$P(y=1|x, v) + P(y=0|x, v) = 1$$

$$P(y=0|x, v) = 1 - h_v(x)$$

$h_v(x) \geq 0.5 \rightarrow \text{close 1}$

$h_v(x) < 0.5 \rightarrow \text{close 0}$

$$\sigma(v^T x) = \frac{1}{1 + e^{-v^T x}}$$

Propriétés



$$1 - \sigma(z) = \sigma(-z)$$

$$\text{Dérivée } \sigma(z) \Rightarrow \frac{d\sigma(z)}{dz}$$

$$= \sigma(z) \cdot (1 - \sigma(z))$$

$$= \sigma(z) \sigma(-z)$$

$$\sigma(z) = \frac{1}{2} + \frac{1}{2} \tanh(\frac{z}{2})$$



$J(\nabla) \Rightarrow$ Fuzzy loss


$$\hat{y} = 1 \Leftrightarrow -3 + x_1 + x_2 \geq 0 \Leftrightarrow x_1 + x_2 \geq 3$$

$$\hat{y} = 0 \Leftrightarrow x_1 + x_2 \leq 3$$

$$q \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \rightarrow \begin{pmatrix} x_1 \\ x_2 \\ x_2 \\ x_2 \\ \vdots \\ x_2 \end{pmatrix} \rightarrow \hat{z}$$




Logistic Regression \rightarrow hyperbolic Paraboloid

$$h_V(x) = \delta(V^T x) \text{ follows a diagonal curve}$$



$$\begin{aligned}
 V_0 &= 1 \\
 V_1 &= 0 \\
 V_2 &= 0 \\
 V_3 &= 1 \\
 V_4 &= 1 \\
 V_5 &= 0
 \end{aligned}$$

Loss Function



$$-\log(1 - h_{\text{sig}}(x))$$

$$\text{Loss}(h_{\text{sig}}(x), y) = \begin{cases} -\log(h_{\text{sig}}(x)) & y=1 \\ -\log(1 - h_{\text{sig}}(x)) & y=0 \end{cases}$$

Gross Entropy Loss Biuniv

$$\text{Loss}(h_{\text{av}}(x), y) = -y \lg(h_{\text{av}}(x)) - (1-y) \lg(1-h_{\text{av}}(x))$$

$y=1$
 $y=0$

$$J(v) = \frac{1}{m} \sum_{i=1}^m \text{Loss}(h_{\text{av}}^{(i)}, y^{(i)})$$

Algorithm di Learning \equiv Risorse pediette

$$\hat{v} = \arg \min_v J(v)$$

$$\text{output} = h_{\text{av}}^{(\hat{v})}(x) = \frac{1}{1 + e^{-\hat{v} \cdot x}} = P(y=1 \mid x, \hat{v})$$


$$v_j \leftarrow v_j - \alpha \frac{\partial J(v)}{\partial v_j}$$

LR

$$\frac{\partial J(v)}{\partial v_j} = \frac{1}{m} \sum_{i=1}^m (h_{\text{av}}^{(i)} - y^{(i)}) x_j^{(i)} \quad \forall j = 0, \dots, d$$



$$v^{*x} \\ \delta(v^*x)$$

$$H(X) = - \sum_{k=1}^K p_k \lg(p_k)$$



$$p_1 = 4 \\ p_2 = 2$$

= Biuniv \Rightarrow



stesso caso anch

$$-0 \lg(0) - 1 \lg 1 = 0$$


$$-g \log \frac{h_{\text{nr}}(\omega)}{p_1} - (1-g) \log \frac{1-h_{\text{nr}}(\omega)}{p_2}$$



Gross Entropy Loss


$$H_f(\omega) = \frac{1}{m} \sum_{k=1}^m \left(-\bar{\sum}_{k=1}^K p_k^{(i)} \log \left(\frac{p_k^{(i)}}{q_k^{(i)}} \right) \right)$$

↓ ↓
 prob input on M ratio dependent
 double double
 no noise white noise



Problemi di classificazione possono essere più complessi

e come appurare?



Modello da dividere
in pettikan

Classificazione Multiclass?

1 Δ 2 □ 3 X → classi


Suddividere problema in 3 sottoproblemi

$$\begin{array}{c} \Delta \\ \times \\ 0 = D \times \end{array}$$

$$h_{\mathcal{V}}^{(1)}(x)$$


dev. logist.

set di regole da derivare classi 1 con altre classi



$$P(g=1|x)$$

ulteriore divisione



more riduttive classi

$$\begin{array}{c} 1 = X \\ 0 = \square \end{array}$$


$$\begin{array}{c} h_{\mathcal{V}}^{(3)}(x) \\ P(g=X|x) \end{array}$$

$$\begin{array}{c} 1 = \square \\ 0 = X \end{array}$$

$$h_{\mathcal{V}}^{(2)}(x)$$

$$0 = \square$$

$$P(g=\square|x)$$



3 classificazioni → Netto pattern mano, e finge pattern complesso

$$\hat{h} = \max_{h} h_{\eta^k}(x^{\min})$$

$$\sum_{i=1 \dots k \text{ classificazione}} h_{\eta^i}(x^{\min}) \neq 1$$

Appari in maniera separata

$$h_{\eta^1}(x^{\min}) = 0.3$$

$$h_{\eta^2}(x^{\min}) = 0.8 \Rightarrow \text{class 2} \rightarrow \text{class mezzina!}$$

$$h_{\eta^3}(x^{\min}) = 0.1$$

Modelli separabile in classi si può usare questa strategia

One vs All

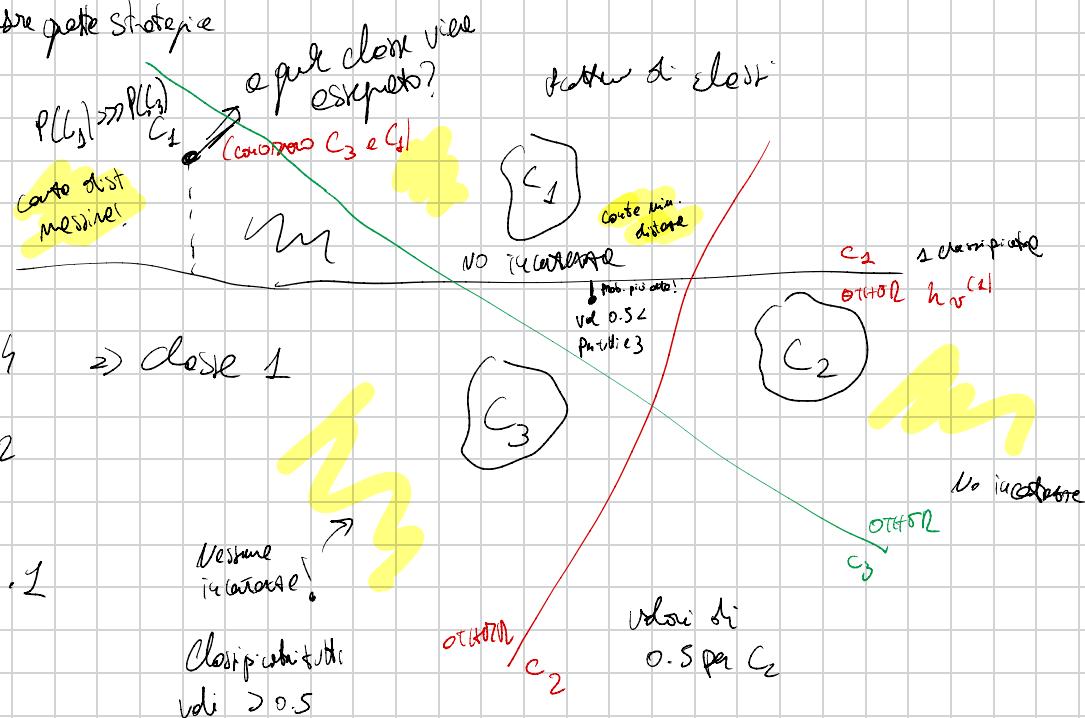
Pattern A VS tutti e sono vicini

One suppose che

$$h_{\eta^1}(x^{\min}) = 0.3 / 0.4 \Rightarrow \text{class 1}$$

$$h_{\eta^2}(x^{\min}) = 0.8 / 0.2$$


$$h_{\eta^3}(x^{\min}) = 0.1 / 0.1$$



In quelle aree dove in box c'è max distanza di borders

These figures in multi-level


One vs one \rightarrow close blue



Compare chi-squared plots for each

1	0	2
1	1	1
? $h_r^{(2)}$ 0.3	$h_r^{(2)}$ 0.4	$h_r^{(3)}$ 0.6

Ovofity in classificazione? sì!



ovofity sui dati \rightarrow non lineare e generalizzabile

Ovofity in questo caso come lo si dissolve?

Applicando il regolare

31:10

Ovofity \rightarrow generalizzabile nelle forme binarie

Generalizzazione Logistic Regression ... 31:34

Softmax

Plide

titolo sopra come me mettere

8 \rightarrow 40 322

18 12 6 \rightarrow 16!

20 12 8
3 2 1

6 1 2
4 1 1